

FBI: Tìm Điểm Mù trong các LLM Đánh Giá Sử dụng Checklist Có Thể Giải Thích Được

Rishav Hada Vaibhav Adlakha Shehzaad Dhuliawala
Mrinmaya Sachan Siva Reddy

McGill / Mila ETH Zürich

EMNLP 2024

<https://aclanthology.org/2024.emnlp-main.911>

250201057	Phan Hồng	Hạnh
250201056	Văn Hồng	Hạnh
250201047	Nguyễn Hải	Đăng
250201078	Nguyễn Bình	Nguyên
250201066	Nguyễn Hoàng Anh	Khoa

- 1 Giới thiệu & Động lực
- 2 Xây Dựng Benchmark
- 3 Các Chiến Lược Đánh Giá
- 4 Kết Quả: GPT-4-Turbo
- 5 Kết Quả Đa Mô Hình & Kết Luận

LLM-as-a-Judge là gì?

- Sử dụng một LLM mạnh (GPT-4, Gemini...) làm **bộ đánh giá tự động** cho đầu ra của các LLM khác
- Ứng dụng: chuẩn mực chatbot, bảng xếp hạng (AlpacaEval, MT-Bench), mô hình phần thưởng RLHF

Tại sao hấp dẫn?

- **~99% rẻ hơn** so với chú thích thủ công
- **Gần tức thì** và mở rộng vô hạn
- Tương quan cao với con người được báo cáo (>80%)

Con người vs. LLM-as-a-Judge

Tiêu chí	Con người	LLM
Tốc độ	Chậm	Nhanh
Chi phí	Cao	Thấp
Mở rộng	Thấp	Cao
Nhất quán	Thấp	Cao
Độ tin cậy	Gold	?

Dù có lợi thế vận hành, **độ tin cậy** của các LLM đánh giá vẫn là câu hỏi mở.

Các sai lệch đã biết của bộ đánh giá LLM

- **Position bias** — ưu tiên câu trả lời đầu tiên trong pairwise
- **Verbosity bias** — ưu tiên câu trả lời dài hơn bất kể độ chính xác
- **Self-preference bias** — ưu tiên đầu ra từ cùng gia đình mô hình

Bẫy tương quan

- Nghiên cứu trước đo tương quan Pearson/Spearman *tổng thể*
- Tương quan cao có thể **ẩn giấu** các lỗi hợp chi tiết
- Không trả lời được: *LLM có thực sự phát hiện các loại lỗi cụ thể không?*

Khoảng Trống Nghiên Cứu

Chưa có nghiên cứu nào thực hiện **đánh giá chi tiết theo từng loại lỗi** của các LLM đánh giá.

Chúng ta cần một *checklist có thể giải thích* để chẩn đoán **blind spot** trước khi tin tưởng LLM làm bộ đánh giá.

Hậu Quả

Nếu các bộ đánh giá có blind spot ẩn $\Rightarrow$ xếp hạng leaderboard **bị sai lệch** $\Rightarrow$ các mô hình tệ hơn được triển khai sản xuất.

Câu hỏi nghiên cứu cốt lõi (RQ): Các bộ đánh giá LLM hiện tại có thể phát hiện đáng tin cậy các lỗi chi tiết qua 4 năng lực cốt lõi không?

RQ1 — Viết Dạng Dài (LF)

Bộ đánh giá có bắt được lỗi mạch lạc, lỗi ngữ pháp, chính tả, mâu thuẫn thứ tự thời gian không?
Ví dụ: “These strategies **is**” thay vì “are”

RQ3 — Tuân Thủ Hướng Dẫn (IF)

Bộ đánh giá có xác định vi phạm định dạng, làm thiếu/thừa, bỏ qua ràng buộc không?
Ví dụ: 6 dòng thay vì 4 dòng yêu cầu

RQ2 — Độ Chính Xác Thực Tế (F)

Bộ đánh giá có phát hiện được việc thay thế thực thể, số sai, sự kiện ngược lại không?
Ví dụ: “Poland” → “London”

RQ4 — Lập Luận (R)

Bộ đánh giá có phát hiện được lỗi số học, công thức sai, đơn vị không đúng không?
Ví dụ: “ $2 + 3 = 6$ ” thay vì 5

FBI = Tìm Điểm Mù trong các LLM Đánh Giá bằng Checklist Có Thể Giải Thích

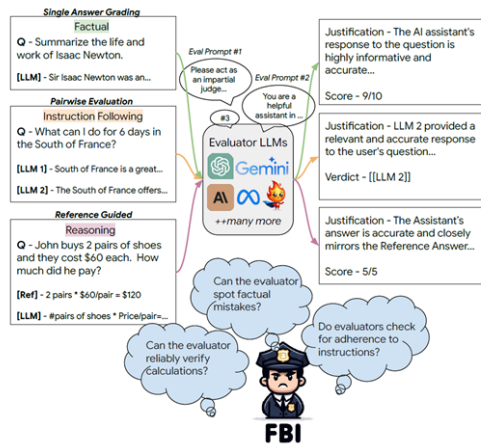
Logic cốt lõi (dựa trên perturbation):

- 1 Bắt đầu từ câu trả lời chuẩn A_{gold} chất lượng cao
- 2 Thêm lỗi có kiểm soát $\rightarrow A_{\text{perturb}}$
- 3 Nạp cho bộ đánh giá; quan sát sự thay đổi điểm số

Bộ đánh giá tốt: $s(A_{\text{perturb}}) < s(A_{\text{gold}})$

Blind spot: $s(A_{\text{perturb}}) \approx s(A_{\text{gold}})$

Quy mô: 4 năng lực · 22 loại lỗi · 2.400 tuple · 17 người chú thích · 3 paradigm · 5 LLM



Hình 1: Pipeline của framework FBI

Đầu vào: 500 prompt từ 6 dataset đã thiết lập

- WizardLM, MT-Bench, UltraChat, LIMA, LLMBBar, IFEval

Pipeline ba giai đoạn:

- 1 **Tạo câu trả lời vàng** — GPT-4-Turbo để tạo ra các câu trả lời chuẩn xác nhất cho từng prompt.
- 2 **Tạo perturbation** — GPT-4-Turbo Tạo ra các biến thể lỗi dựa trên 22 danh mục lỗi cụ thể.
- 3 **Kiểm tra bởi con người** — 17 sinh viên sau đại học kiểm tra tính hợp lệ của perturbation.

Đầu ra: 2.400 tuple (*prompt*, A_{gold} , A_{perturb})

Nguyên Tắc Thiết Kế

Benchmark **không** đo trực tiếp chất lượng câu trả lời. Nó đo **khả năng phát hiện lỗi của bộ đánh giá** — một nhiệm vụ khác và khó hơn về cơ bản.

Nhãn Annotation

- **Valid** — lỗi rõ ràng tồn tại
- **Invalid** — lỗi không tồn tại / sai loại
- **Score-Invariant** — thay đổi vô hại
- **Not Relevant** — prompt lạc đề
- **Not Sure**

Các Danh Mục Cốt Lỗi

Category	# Instances
Long Form (LF)	528
GRAMMAR	92
SPELLING	100
CONSISTENCY	84
CHRONOLOGY	71
COHERENCE	91
COMPREHENSIVENESS	90
Factual (F)	483
CONTEXTUAL	94
ENTITY	87
INCORRECT FACT	68
NUMBER ERRORS	74
OPPOSITE FACT	91
REMOVE FACT	69
Instruction Following (IF)	379
DO MORE	50
DO LESS	100
IGNORE FORMAT	99
SEQUENCE ERRORS	49
ASSUMPTIONS	81
Reasoning (R)	494
CALCULATIONS	149
COPYING NUMBERS	83
FINAL ERRORS	97
INCORRECT UNITS	77
WRONG FORMULA	88
Score Invariant (SI)	516
Total	2400

Table 1: Statistics of perturbations across all the 4 task

Viết Dạng Dài (LF)

Bài luận sáng tạo/phân tích. “*Làm thế nào để cải thiện quản lý thời gian?*” — lỗi cần đọc toàn bộ tài liệu.

Thực Tế (F)

Câu hỏi có thể kiểm chứng khách quan. “*Chức năng của tụ điện là gì?*” — lỗi cần kiểm tra kiến thức thế giới.

Tuân Thủ Hướng Dẫn (IF)

Tạo sinh có ràng buộc. “*Viết bài thơ 4 dòng dùng: peace, sky, race, ground.*” — lỗi cần kiểm tra ràng buộc.

Lập Luận (R)

Bài toán toán học/logic. “*Gậy+bóng = \$1,10; gậy đắt hơn \$1. Bóng giá bao nhiêu?*” — lỗi cần kiểm tra từng bước.

22 Danh Mục Perturbation (Bảng 2)

Task	Perturbation Axis	Description
LF	GRAMMAR	Introducing grammatical errors in the answer. Eg: This is good → This are good .
	SPELLING	Introducing “valid” spelling errors in the answer. Eg: Toxicity → Tocixity .
	CONSISTENCY	Introducing errors in the “consistency” of the answer (like tone, terminology, etc.)
	CHRONOLOGY	Introducing errors in the chronological or the logical flow of the answer.
	COHERENCE	Introducing errors that affect the coherence of the answer.
F	COMPREHENSIVENESS	Introducing vagueness, irrelevance or lack of context in the answer.
	CONTEXTUAL	Replacing fact with a contextually similar incorrect fact. Eg: electricity → magnetism .
	ENTITY	Replacing a named entity with an incorrect entity. Eg: Poland → London .
	INCORRECT FACT	Adding a new contextually relevant incorrect fact in the answer.
	NUMBER ERRORS	Introducing errors in the various numbers reported in the answer. Eg: 1987 → 1887 .
IF	OPPOSITE FACT	Replacing a fact in the answer with its negation. Eg: ... will have ... → ... wont have
	REMOVE FACT	Removing a fact critical to the correctness and completeness of the answer.
	DO LESS	Doing less than what is <i>explicitly</i> requested in the question.
	DO MORE	Doing more than what is <i>explicitly</i> requested in the question.
	IGNORE FORMAT	Ignoring the formatting and other constraints mentioned in the question.
R	SEQUENCE ERRORS	Ignoring the sequence in the response when <i>explicitly</i> requested in the instruction.
	ASSUMPTIONS	Making new incorrect assumptions about the instruction.
	CALCULATIONS	Introducing calculation errors in the answer. Eg: 2 + 3 = 5 → 2 + 3 = 6
	COPYING NUMBERS	Introducing errors while considering the numbers mentioned in the instruction.
	FINAL ERRORS	Introducing errors only the final reported answer while retaining the correct solution.
SI	INCORRECT UNITS	Introducing errors in the units reported and considered in the answer.
	WRONG FORMULA	Introducing errors in the formula used in the answer. Eg: πr^2 → $2\pi r$
	SCORE INVARIANT	Introducing modifications in the answer which would not result in a score penalty.

Bảng 2: Tất cả 22 danh mục perturbation qua 4 loại nhiệm vụ

Nguyên tắc thiết kế:

- Mỗi perturbation chỉ nhắm một **chiều lỗi**
- Lỗi có thể **giải thích được** — diễn giải với checklist
- Tránh các thay đổi đồng thời gây nhiễu attribution

Ví dụ nhanh:

- *Entity*: “Poland” → “London”
- *Tính toán*: $2 + 3 = 5 \rightarrow 2 + 3 = 6$
- *Do More*: thơ 4 dòng → 6 dòng
- *Chronology*: sắp xếp lại sự kiện lịch sử

22 danh mục bao phủ **các lỗi thường gặp nhất** trong thực tế của văn bản LLM.

Tạo Lỗi Tự Động & Human-in-the-Loop

Instructions to evaluate a document: [Link](#)

Enter your name

There are 1 pending documents for you.

Question

Summarize the concept of quantum mechanics in a paragraph.

Perturbation type

Introducing an incorrect fact in the answer

Expected Perturbation

The introduced error is the claim that energy is absorbed or emitted in discrete units termed photons. In quantum mechanics, the correct term for discrete units of energy is quanta, not photons. Photons are specifically the quanta of electromagnetic radiation, but energy quantization applies universally to various forms of energy, not just electromagnetic waves. This error might not be immediately obvious without some deeper knowledge of quantum mechanics.

Original Text	Perturbed Text
Quantum mechanics is a fundamental theory in physics that describes the physical properties of nature at the scale of atoms and subatomic particles. Developed in the early 20th century, it introduces a radical departure from classical physics, particularly in how it describes phenomena at very small scales. Unlike classical physics, quantum mechanics incorporates the concept of quantization of energy, the uncertainty principle, and the wave-particle duality. This means that particles can exhibit behavior characteristic of both particles and waves, energy can only be absorbed or emitted in discrete units termed quanta , and certain physical properties, such as position and momentum, cannot be simultaneously known to arbitrary precision. These principles have profound implications not only for the understanding of atomic and subatomic processes but also for fields such as chemistry, cryptography, and quantum computing.	Quantum mechanics is a fundamental theory in physics that describes the physical properties of nature at the scale of atoms and subatomic particles. Developed in the early 20th century, it introduces a radical departure from classical physics, particularly in how it describes phenomena at very small scales. Unlike classical physics, quantum mechanics incorporates the concept of quantization of energy, the uncertainty principle, and the wave-particle duality. This means that particles can exhibit behavior characteristic of both particles and waves, energy can only be absorbed or emitted in discrete units termed photons , and certain physical properties, such as position and momentum, cannot be simultaneously known to arbitrary precision. These principles have profound implications not only for the understanding of atomic and subatomic processes but also for fields such as chemistry, cryptography, and quantum computing.

Feedback

Label

☒ Valid Perturbation ☐ Score-Invariant Perturbation ☐ Invalid Perturbation ☐ Not Sure

Comments

Pipeline tạo perturbation + kiểm tra human-in-the-loop

Các lỗi phổ biến trong perturbation tự động:

- 1 GPT-4-Turbo **lệch** sang loại lỗi sai
- 2 Lỗi quá nhẹ hoặc quá rõ ràng
- 3 Giải thích nhắc đến lỗi nhưng **văn bản không phản ánh**

Thiết lập: 17 sinh viên cao học review toàn bộ 2,400 perturbation

Dán nhãn mỗi perturbation:

Valid / Invalid / Score-Invariant /
Không liên quan / Không chắc

Invalid $\Rightarrow$ tạo lại cho đến khi hợp lệ.

Score-Invariant (SI): 516 trường hợp

Thay đổi chỉ paraphrase **không** nên giảm điểm.
Dùng để phát hiện **bộ đánh giá quá khắt khe**.

Ba Paradigm Đánh Giá

Paradigm 1 Chấm Điểm Một Câu Trả Lời

Instruction + A_{perturb}



Điểm số (1–3)

5 chiến lược prompting

Paradigm 2 So Sánh Cặp (Pairwise)

Instruction + A_{gold} vs. A_{perturb}



Phán quyết (đầu)

5 chiến lược prompting

Paradigm 3 Chấm Điểm Có Tài Liệu Tham Chiếu

Instruction + A_{gold} (tham chiếu) +
 A_{perturb}



Điểm số (1–3)

1 chiến lược (thông tin nhất)

Metric: % perturbation **không được phát hiện** (điểm số không đổi)
↓ thấp hơn là tốt | SI↑ cao hơn là tốt (không false positive)

5 LLM đánh giá: GPT-4-Turbo,
Gemini-1.5-Pro, Claude-3-Opus,
LLaMA-3-70B-Instruct, Prometheus 2

Chiến lược	Đầu vào	Đầu ra
Vanilla*	Instruction + Answer	Chỉ điểm số
Vanilla	Instruction + Answer	Giải thích → Điểm số
Rubric	Instruction + Answer + Rubric chấm	Giải thích → Điểm số
Axis	Instruction + Answer + Trục đánh giá	Giải thích → Điểm số
Axis+Rubric	Instruction + Answer + Axis + Rubric	Giải thích → Điểm số

Giả thuyết: hướng dẫn nhiều hơn $\Rightarrow$ phát hiện tốt hơn

Axis = chiều khớp với nhiệm vụ (ví dụ: “factual accuracy” cho nhiệm vụ F)

Rubric = tiêu chí chấm điểm chi tiết theo từng chiều

Tình báo trước

Thêm rubric/axis **làm giảm** hiệu suất phát hiện trong chấm điểm một câu trả lời — sẽ giải thích thêm trong Kết quả.

Chiến lược	Đầu vào	Đầu ra
Pairwise*	Instruction + A_1, A_2	Chỉ phán quyết
Pairwise	Instruction + A_1, A_2	Giải thích → Phán quyết
Rules	Instruction + A_1, A_2 + Quy tắc	Giải thích → Phán quyết
Axis	Instruction + A_1, A_2 + Axis	Giải thích → Phán quyết
Axis+Rules	Instruction + A_1, A_2 + Axis + Quy tắc	Giải thích → Phán quyết

Kiểm soát position bias:

- Chạy **hai lần**, đảo vị trí của $A_{\text{gold}}/A_{\text{perturb}}$
- Chỉ tính là phát hiện nếu bộ đánh giá nhất quán ưu tiên A_{gold}

Điểm khác chính với một câu trả lời

Trong pairwise, chiến lược nâng cao **có ích** — bộ đánh giá dùng quy tắc như *checklist so sánh*, không phải neo điểm cố định.

Chiến lược	LF↓	F↓	IF↓	R↓	SI↑
Vanilla*	63	58	63	30	60
Vanilla	57	54	57	25	71
Rubric	85	73	80	33	96
Axis	83	74	75	43	96
Axis+Rubric	86	76	77	37	97

Tất cả giá

trị = % không được phát hiện. ↓ thấp hơn = tốt hơn; SI↑ cao hơn = tốt hơn.

Phát hiện chính:

- Vanilla là **chiến lược tốt nhất** (đơn giản là thắng)
- **Rubric/Axis làm xấu hơn** rõ rệt — tới +29pp
- Lập luận (**25%**) được phát hiện tốt hơn nhiều so với LF/F/IF

Nghịch Lý Rubric

Hướng dẫn nhiều hơn $\neq$ phát hiện tốt hơn.
Rubric **neo** mô hình vào các tiêu chí liệt kê và khiến nó bỏ qua các lỗi ngoài phạm vi rubric.

Chiến lược	LF↓	F↓	IF↓	R↓	SI↑
Pairwise*	73	52	83	36	93
Pairwise	77	46	67	35	74
Rules	75	63	68	41	74
Axis	64	44	59	27	71
Axis+Rules	64	42	61	32	72

Tất cả giá

trị = % không được phát hiện.

Đảo chiều mô hình:

- Chiến lược nâng cao có ích trong pairwise (ngược với chấm một câu)
- Axis+Rules: tốt nhất cho F (42%) và LF (64%)

Tại sao khác nhau?

Trong pairwise, bộ đánh giá có ngữ cảnh so sánh trực tiếp. Quy tắc đóng vai trò checklist sự khác biệt, không phải neo điểm tuyệt đối.

Vẫn còn: 64% LF và 61% IF không được phát hiện dù với chiến lược tốt nhất.

Task	Tham chiếu	Vanilla	Cải thiện
LF	26%	57%	−31 pp ($\sim 2\times$)
F	11%	54%	−43 pp ($\sim 5\times$)
R	4%	25%	−21 pp (gần hoàn hảo)
IF	49%	57%	−8 pp (vẫn cao!)

Thành công:

- Lỗi thực tế: **11%** không phát hiện — tham chiếu giúp so sánh sự kiện
- Lập luận: **4%** — bộ đánh giá có thể kiểm tra toán với tham chiếu

Blind Spot Dai Dẳng: IF (49%)


Thậm chí có câu trả lời chuẩn, gần một nửa vi phạm instruction-following không được phát hiện.

Lí do: Lỗi IF cần so sánh câu trả lời với **instruction**, không phải với tham chiếu. Câu chuẩn không cho biết ràng buộc có được thỏa hay không.

Hạn Chế Thực Tế

Đánh giá có tham chiếu **không áp dụng được** cho câu hỏi mở trong triển khai thực tế.

Sự Phân Tách Kiến Thức – Điểm Số (Hình 2)



Hình 2: Các trường hợp phát hiện qua giải thích vs. điểm số

Q: Đọc *giải thích* có tiết lộ được nhiều lỗi hơn không?

Phương pháp: Với mỗi trường hợp không phát hiện, kiểm tra với GPT-3.5-Turbo xem *giải thích* có *đề cập* lỗi không.

Kết quả: Vanilla chỉ khôi phục **~36 trường hợp bổ sung** / 904 không phát hiện (<4%).

Phát Hiện Then Chốt

Bộ đánh giá **đề cập đến lỗi** trong *giải thích* nhưng vẫn **cho điểm hoàn hảo**.

“The answer contains a grammatical error...” → Score: 3/3

Nguyên Nhân Gốc Rễ

Không phải vấn đề **nhận thức** — LLM thấy lỗi.

Đây là vấn đề **hiệu chỉnh mức độ nghiêm trọng** — LLM không phạt các lỗi nhỏ theo đánh giá của chúng.

Strategy	Model	LF↓	F↓	IF↓	R↓	SI↑
Vanilla		0.57	0.54	0.57	0.25	0.71
		0.61	0.73	0.54	0.41	0.71
		0.74	0.84	0.75	0.47	-
		0.86	0.95	0.90	0.71	0.75
Axis+Rules		0.64	0.42	0.61	0.32	0.72
		0.72	0.58	0.70	0.39	0.65
		0.75	0.69	0.70	0.60	0.64

Bảng 4 (phần không tham chiếu): % không phát hiện theo mô hình

- **GPT-4-Turbo** là bộ đánh giá không tham chiếu mạnh nhất
- **Gemini-1.5-Pro**: hạng trung, mạnh về IF một câu trả lời
- **Claude-3-Opus**: kém hơn GPT và Gemini (chỉ test Vanilla do chi phí API)
- **LLaMA-3-70B**: bỏ lỡ >85% lỗi LF/F/IF

Kết Luận Chính

Thậm chí **GPT-4-Turbo** vẫn bỏ lỡ >50% lỗi trong LF, F, IF khi không có câu trả lời tham chiếu.

Reference		0.26	0.11	0.49	0.04	0.63
		0.25	0.07	0.17	0.03	0.33
		0.03	0.01	0.05	0.05	0.13
		0.51	0.62	0.53	0.12	0.38

Bảng 4 (phần có tham chiếu): % không phát hiện + điểm SI

LLaMA trông gần hoàn hảo (1–5% không phát hiện).
Nhưng SI↑: LLaMA chỉ cho điểm đầy đủ trong **13%** trường hợp score-invariant.
⇒ Nó phạt cả các câu trả lời **đúng nhưng đã được diễn giải lại**.

Bẫy Bộ Đánh Giá Quá Khắt Khe

Một mô hình có thể cho điểm không phát hiện thấp đơn giản bằng cách **phạt tất cả** — kể cả câu trả lời đúng.
Số tốt $\neq$ bộ đánh giá tốt.
Kiểm tra **cả hai** tỉ lệ phát hiện và tỉ lệ false positive (SI).

Bài Học

Luôn bao gồm các trường hợp **score-invariant** để kiểm tra tính quá khắt khe.

Prometheus 2: Huấn Luyện Chuyên Biệt Có Giúp Ích?

Reference		0.26	0.11	0.49	0.04	0.63
		0.25	0.07	0.17	0.03	0.33
		0.03	0.01	0.05	0.05	0.13
		0.51	0.62	0.53	0.12	0.38

Bảng 4 (phần Prometheus 2, có tham chiếu)

Prometheus 2: fine-tuned trên phản hồi con người chuyên biệt cho đánh giá.

Kỳ vọng: mô hình chuyên biệt nên vượt LLM đa năng.

Thực tế: thua GPT-4-Turbo gần như mọi danh mục.
Thực tế: GPT **11%** vs. Prometheus **62%**

Kết Luận Chính

Huấn luyện chuyên biệt **không** giải quyết blind spot.

Prometheus học *bắt chước* mô hình chấm của con người, chứ không thực sự *phát hiện* lỗi.

Ý Nghĩa

Cần các mục tiêu huấn luyện tốt hơn — không chỉ fine-tune nhiều hơn trên cùng tín hiệu phản hồi.

Dễ Phát Hiện Nhất — Lập Luận

- Lỗi tính toán (ví dụ: $2 + 3 = 6$)
- Công thức sai
- Đơn vị không đúng

Lí do: Bộ đánh giá có thể kiểm chứng toán học; lỗi **quan sát được cục bộ**.

Khó Phát Hiện Nhất (>90% không phát hiện)

Lỗi	Không PH
Chronology (LF)	~100%
Comprehensiveness (LF)	91–100%
Remove Fact (F)	94–99%
Assumptions (IF)	95–98%

Mô Hình: Lỗi Cục Bộ vs. Phân Tán

Bộ đánh giá phát hiện tốt các lỗi **cục bộ, có thể kiểm chứng**.
Bộ đánh giá thất bại với các lỗi **tinh tế, trải rộng** cần đọc toàn bộ tài liệu.

Kết luận chính:

- 1 LLM bỏ lỡ **>50% lỗi** trung bình thậm chí với mô hình tốt nhất (GPT-4-Turbo)
- 2 Vấn đề là **hiệu chỉnh mức độ nghiêm trọng**, không phải nhận thức — LLM thấy lỗi nhưng không phạt
- 3 Bộ đánh giá chuyên biệt (Prometheus 2) **không** vượt GPT-4-Turbo
- 4 Đánh giá có tham chiếu giúp ích đáng kể nhưng **không phải lúc nào cũng áp dụng được**

Khuyến nghị thực tế:

- ✓ Ưu tiên **đánh giá có tham chiếu** khi có câu trả lời chuẩn
- ✓ Dùng **prompt đơn giản** hơn là rubric phức tạp trong chấm một câu
- ✓ Luôn bao gồm trường hợp **score-invariant** để phát hiện bộ đánh giá quá khắt khe
- ✗ Không tin mù quáng vào leaderboard và benchmark dựa trên LLM

Hướng nghiên cứu tương lai:

- Đánh giá đa ngôn ngữ
- Bộ đánh giá đa tác nhân / tranh luận
- Cơ chế hiệu chỉnh tốt hơn
- Nhiệm vụ sử dụng công cụ và lập kế hoạch

“LLM có thể *tạo sinh* văn bản rất tốt,
nhưng *đánh giá* chất lượng văn bản là
khó hơn nhiều so với những gì chúng ta đã giả định.”

FBI: Tìm Blind Spot trong các LLM Đánh Giá
Sử dụng Checklist Có Thể Giải Thích Được

Hada et al. — EMNLP 2024

<https://aclanthology.org/2024.emnlp-main.911>